Grupowanie

Główną ideą grupowania jest podział zbioru próbek na kilka grup (klastrów) i ew. wyznaczenie środka tych grup. Wszystkie próbki w danym klastrze powinny znajdować się w miarę blisko siebie (blisko tzw środka grupy) oraz jak najdalej od innych grup (i ich środków).

Przygotowanie zbioru próbek

W ćwiczeniu będziemy operować na zbiorze próbek zapisanych w macierzy "probki". Każda próbka posiada 2 atrybuty i zawarta jest w pojedynczym wierszu macierzy "probki". Można je wygenerować za pomocą poniższego skryptu napisanego z języku Octave, ale najlepiej użyć gotowej tablicy z próbkami podanej niżej.

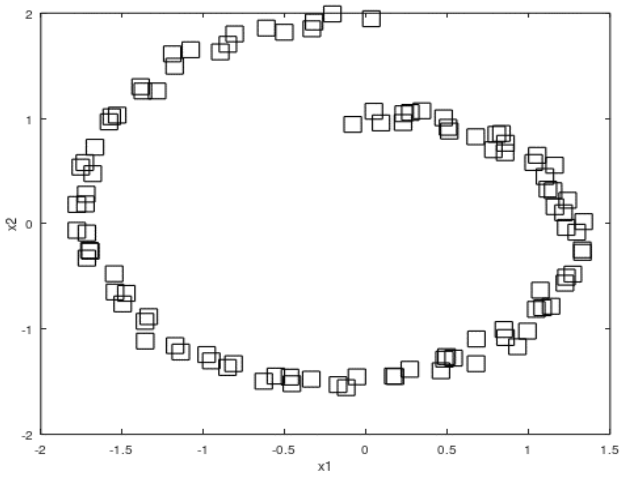
```
rand('seed', 123);
n = 2; %liczba atrybutow
M = 101; % liczba probek
%tworzenie zbioru probek
t= 1:0.01:2;
probki = [  t.*sin(t*2*pi)-0.1+0.2*rand(1,length(t))  ; ...
   t.*cos(t*2*pi)-0.1+0.2*rand(1,length(t))   ]' ;
clear t;
plot(probki(:,1), probki(:,2), 'sk'); xlabel('x1'); ylabel('x2');
```

Baza próbek spiralka.csv

Każda kolumna określa parametr1 (x1) i parametr2 (x2), pojedynczy wiersz to pojedyncza próbka i jednocześnie pojedynczy punkt:

```
-0.0824,0.9435
0.0913,0.9575
0.0476,1.0683
0.2311,1.0452
0.2269,0.9615
0.2717,1.057
0.343,1.0724
0.4765,1.006
0.5039,0.9162
0.5113,0.8803
0.6735,0.8263
0.803,0.8494
0.8318,0.8573
0.7825,0.7032
0.8566,0.7646
0.8544,0.6752
1.0519,0.6502
1.0302,0.5818
1.1587,0.5559
1.0992,0.4486
1.1175,0.3286
1.1493,0.3144
1.1607,0.1619
1.2388,0.2232
1.2136,0.1041
1.3375,0.0204
1.2301,-0.0344
1.2946,-0.0799
1.3301,-0.2716
1.3287,-0.248
1.2707,-0.4779
1.2219,-0.564
1.2314,-0.5076
1.071,-0.6311
1.0461,-0.8127
1.085,-0.7972
1.1371,-0.7834
0.9918,-1.0194
0.8467,-1.0041
0.9301,-1.1675
0.8569,-1.0805
0.6782,-1.0943
0.6759,-1.3292
0.5377,-1.276
0.4944,-1.2617
0.4819,-1.2857
0.4601,-1.3957
0.2684,-1.382
0.1669,-1.4465
0.1774,-1.4508
-0.0566,-1.4538
-0.1226,-1.5564
-0.1725,-1.5277
-0.3374,-1.4758
-0.4568,-1.5191
-0.4682,-1.4563
-0.5552,-1.4464
-0.6295,-1.4956
-0.8523,-1.3649
-0.8152,-1.3287
-0.952,-1.3021
-0.9805,-1.2422
-1.1398,-1.2181
-1.1746,-1.157
-1.3583,-1.1144
-1.3366,-0.8821
```

```
-1.3595,-0.9266
-1.4969,-0.7615
-1.5441,-0.6479
-1.4743,-0.6608
-1.5488,-0.4747
-1.7169,-0.3264
-1.7011,-0.2524
-1.6954,-0.2604
-1.7168,-0.0879
-1.779,-0.0625
-1.7251,0.1885
-1.7787,0.1831
-1.7208,0.2806
-1.7544,0.5381
-1.681,0.476
-1.7296,0.5807
-1.6673,0.727
-1.5808,0.968
-1.5305,1.0313
-1.5638,1.0163
-1.3728,1.2606
-1.2852,1.2611
-1.3866,1.3016
-1.1773,1.4962
-1.1918,1.6133
-1.0784,1.6521
-0.8967,1.6324
-0.8501,1.7047
-0.8084,1.8031
-0.6135,1.8584
-0.5031,1.8191
-0.334,1.8515
-0.32,1.9158
-0.2074,1.9929
0.0322,1.9473
```



Miara odległości

Istnieje wiele różnych miar liczących odległość między próbkami. Oto przykład najpopularniejszych z nich:

- euklidesowa - $odleglosc(pktA, pktB) = \sqrt{\sum_{i=1..n}(pktA_i - pktB_i)^2}$, gdzie i to liczba wymiarów, $pktA_i$ to wartość i-tego wymiaru punktu pktA;
- manhattan (taksówkowa) - $odleglosc(pktA, pktB) = \sum_{i=1..n}|pktA_i - pktB_i|$;
- Czebyszewa - $odleglosc(pktA, pktB) = max_{i=1..n}|pktA_i - pktB_i|$;
- Minkowskiego - $odleglosc(pktA, pktB) = \left(\sum_{i=1..n}|pktA_i - pktB_i|^{mink}\right)^{1/mink}$, gdzie mink to parametr sterujący, mink > 0.

Wszystkie te miary zakładają, że oba punkty są liczbami jedno/wielowymiarowymi.

Algorytm K-średnich

Algorytm tworzy *k* grup, każda z tych grup posiada środek (średnią z grupy). Algorytm działa w ten sposób, iż przez zadaną liczbę iteracji na przemian określa dla każdej próbki przynależność do każdej z grup (czyli do którego z *k* środków ma najbliżej) a następnie dla każdej z poprzednio ustalonej grupy wyznacza osobno środek. Algorytm do poprawnego zadania musi zawierać informację n/t środków *k* grup oraz musi posiadać informację n/t tego, które próbki mają najbliżej

do danej grupy. Start algorytmu, liczba grup, iteracji i miara odległości nie jest z góry ustalona. W tym przykładzie zaleca się użyć 4 grup (*m*=4), 100 iteracji miary odległości euklidesowej a na początku ustalenie środka grup równe losowo wybranej grupie różnych próbek.

Algorytm zapisany w postaci pseudokodu:

1. Wybierz losowo *m* różnych próbek i uznaj je jako środki grup (V)

2. Pętla wykonywana zadaną liczbę iteracji (*iters*)

2.1. Pętla po wszystkich M próbkach, *s* to indeks aktualnej próbki

2.1.1. Wylicz odległości między próbką *s* a każdym środkiem grupy (V)

2.1.2. Wyznacz u_s równy indeksowi najbliższego środka grupy

2.2. Pętla po wszystkich m grupach, *j* to indeks aktualnej grupy

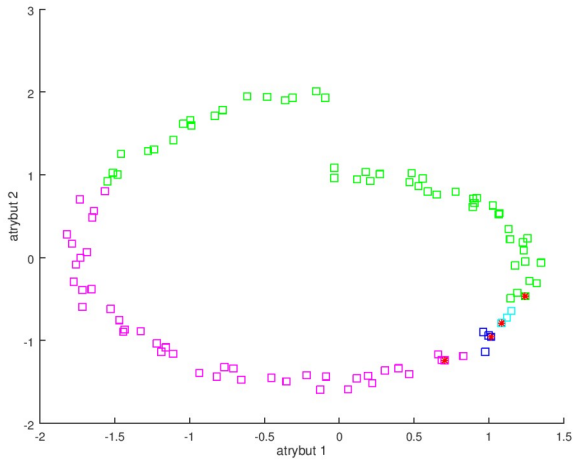
2.2.1. Wybierz próbki, należące do tej grupy (zbiór próbek o indeksach *s,* takich, że $u_s == j$*),* niech zbiór ten nazywa się X_{gr}

2.2.2. Jeśli zbiór X_{gr} jest pusty, wtedy pomiń wykonanie dalszej części tej pętli.

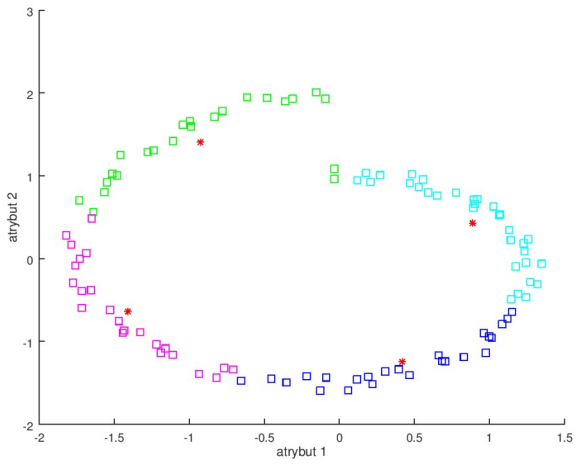
2.2.3. Pętla po wszystkich atrybutach, *i* to index poszczególnego atrybutu

2.2.3.1 Wartość *i*-tego atrybutu grupy *j*-tej to średnia wartość atrybutu *i*-tego wszystkich próbek X_{gr}

Przykład podziału na 4 grupy przed działaniem algorytmu k-średnich, odległość liczona metodą euklidesową:



Przykład podziału na 4 grupy po 11 iteracjach algorytmu k-średnich, odległość liczona metryką euklidesową:



Algorytm Fuzzy c-Means (FCM) **(nieobowiązkowy, na bdb)**

Algorytm jest rozszerzeniem algorytmu k-średnich. Każda próbka nie należy do dokładnie jednej z grup lecz należy do każdej z grup w różnym stopniu (stąd słowo fuzzy - rozmyty w nazwie algorytmu). Stopień rozmywania ustalony jest przez pojedynczy parametr nazwany tutaj fcm_m (fcm_m>1, domyślnie równy 2). Najpierw następuje start algorytmu, następnie wykonywany jest on w wielu iteracjach. W każdej z nich najpierw obliczana jest odległość między każdą próbką i grupą:

$$D_{j,s} = d(x_s, v_j)^2,$$

gdzie j to numer grupy (j=1..m), m to liczba grup, s to numer próbki (s=1..M), M to liczba próbek, d(…) to odległość. Następnie liczona jest przynależność (U) poszczególnej próbki do każdej z grup:

$$U_{j,s} = D_{j,s}^{1/(1-fcm_m)} / \left(\sum_{j'=1}^{m} D_{j',s}^{1/(1-fcm_m)}\right)$$

gdzie *fcm_m* to parametr algorytmu FCM określający sposób rozmywania, *fcm_m>1* i domyślnie jego wartość to 2, M to liczba próbek, s to numer próbki.

Warto wspomnieć, iż

$$\forall_s : \sum_{j=1}^{m}(U_{j,s}) = 1$$

czyli suma przynależności pojedynczej próbki do wszystkich grup wynosi 1. Kolejnym krokiem jest obliczenie nowej wartości środków grup używając wzoru

$$V_{j,i}^{(t+1)} = \left(\sum_{s=1}^{M} U_{j,s}^{fcm_m} x_{s,i}\right) / \left(\sum_{s=1}^{M} U_{j,s}^{fcm_m}\right),$$

gdzie i to numer atrybutu (i=1..n), n to liczba atrybutów, s to numer próbki (s=1..M), M to liczba próbek, x to wartości próbki, $V_{j,i}^{(t+1)}$ to wartość i-tego atrybutu środka j-tej grupy w kolejnej iteracji algorytmu FCM.

Przykład implementacji algorytmu zapisany w pseudokodzie

1. Inicjalizacja algorytmu

1.1 Stworzenie tablic U i D o rozmiarze m x M, gdzie m to liczba klas, a M to liczba próbek (wartość dowolna)

1.2 Utworzenie tablicy V ze środkami grup o rozmiarze m x n, gdzie m to liczba grup, a n to liczba atrybutów (wartość dowolna).

1.3 Wypełnienie tablicy D losowymi wartościami dodatnimi, na przykład z przedziału (0,1; 1,1).

1.4 Wyliczenie każdej wartości w tablicy $U_{j,s}$ (j=1..m; s=1..M).

1.5 Obliczenie środków grup $V_{j,i}$ (j=1..m; i=1..n; m to liczba grup, n to liczba atrybutów)

2. Główna pętla programu wykonywana przez zadaną liczbę iteracji.

2.1. Obliczenie odległości między każdą próbką a grupą: $D_{j,s}$ (j=1..m; s=1..M, m to liczba grup, M to liczba próbek)

2.2. Należy zadbać, aby wszystkie wartości w tablicy D były większe od ustalonej małej wartości (na przykład wszystkie wartości < 1e-5 zastąpić 1e-5).

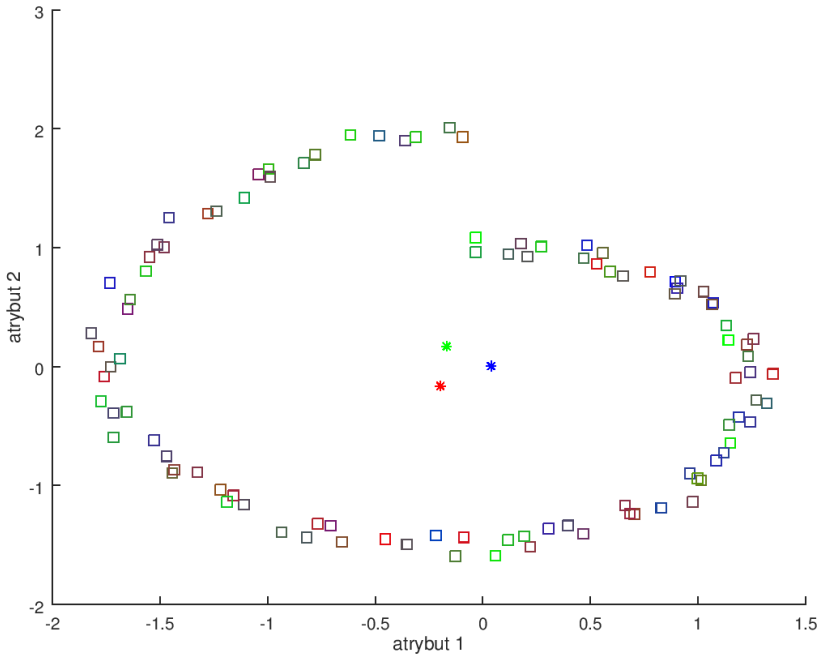
2.3. Wyliczenie stopnia przynależności poszczególnej próbki do każdej grupy: $U_{j,s}$ (j=1..m; s=1..M, m to liczba grup, M to liczba próbek).

2.4. Należy sprawdzić, czy przypadkiem U nie zawiera wartości nieoznaczonych (w takim przypadku należy przerwać program i wyświetlić komunikat ostrzegawczy)

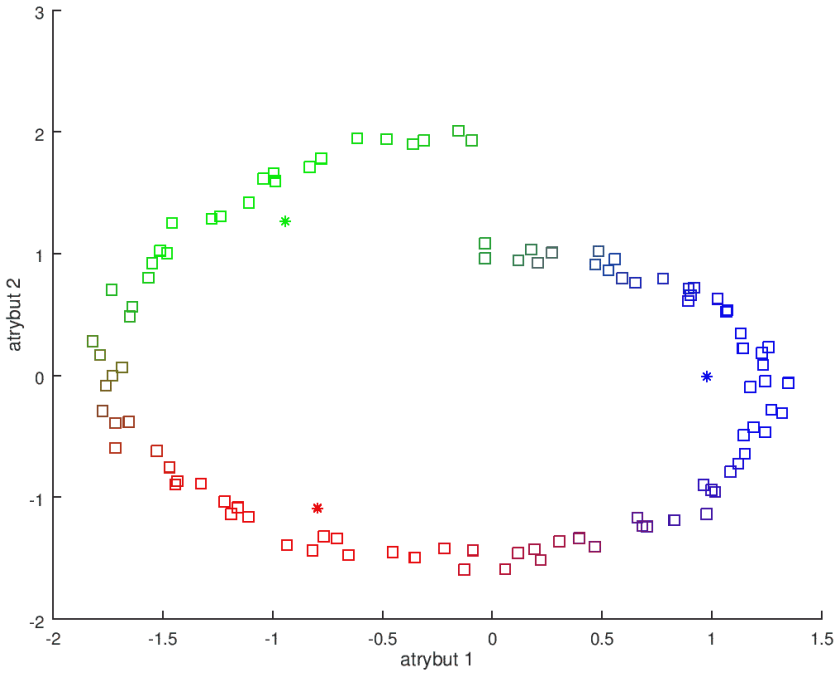
2.5. Obliczenie nowych położeń środków grup $V_{j,i}$ (j=1..m; i=1..n; m to liczba grup, n to liczba atrybutów).

Przykład działania grupowania tych samych próbek przy pomocy FCM na 3 grupy. Na poniższym rysunku widać początkowy rozkład przynależności (przy pomocy kolorów) każdej z próbek (V) do jednej z 3 grup. Użyto to miary odległości euklidesowej oraz parametru fcm_m=2.

Przykład działania przed wykonaniem głównej pętli:



a następnie położenie środków grup i podział na grupy po 10 iteracjach:



Raport

1. Raport (k-średnie)

- Miara odległości euklidesowa
- liczba grup: 3
- liczba iteracji: 10 (należy podać dane do raportu po 4 i po 10 iteracjach przy pojedynczym uruchomieniu algorytmu)
- zawartość raportu:
  - Położenie każdego ze środków po 4 iteracjach, liczba próbek należących do każdej z tych grup, minimalna i maksymalna wartość obu parametrów (x1, x2) próbek należących dla każdej z tych grup.
  - Wykres zawierający położenie środka oraz zawartość każdej z grup po 4 iteracjach. Można na przykład stworzyć wykres zawierający cztery serie danych: a) próbki należące do grupy 1., b) próbki należące do grupy 2., c) próbki należące do grupy 3., d) środki grup.
  - To samo co uprzednio, ale po 10 iteracjach.

2. Raport (k-średnie)

- Miara odległości następująca: $odleglosc(pktA, pktB) = |pktA_1 - pktB_1|$, czyli brany będzie pod uwagę tylko parametr x1 i ignorowany x2.
- liczba grup: 4
- liczba iteracji: 10
- zawartość raportu:
  - Położenie każdego ze środków po 10 iteracjach, liczba próbek należących do każdej z

tych grup, minimalna i maksymalna wartość obu parametrów (x1, x2) próbek należących dla każdej z tych grup.

- Wykres zawierający położenie środka oraz zawartość każdej z grup po 4 iteracjach.

3. Raport (FCM) **(nieobowiązkowy, na wyższą ocenę)**

- Miara odległości euklidesowa,
- liczba grup: 3
- współczynnik/parametr fcm_m = 2
- liczba iteracji: 20 (należy podać dane do raportu po 4 i po 20 iteracjach przy pojedynczym uruchomieniu algorytmu)
- zawartość raportu:
  - Stan po 4 iteracjach: położenie każdego ze środków, liczba próbek, które przynależą w stopniu > 0.6 do każdej z tych grup, minimalna i maksymalna wartość obu parametrów (x1, x2) próbek przynależących w stopniu > 0.6 dla każdej z tych grup.
  - To samo co uprzednio, ale po 20 iteracjach.